

REGISTRO DE IA - SEMANA 13

Parte 1 – O básico da tokenização

Teste: “Olá, mundo!”

Item	Resposta
Número de tokens	Verificar no tokenizador
Tokens gerados com IDs	Verificar no tokenizador
Observação	Geralmente a vírgula e o ponto de exclamação aparecem como tokens separados. Em muitos tokenizadores, o espaço fica associado ao início da palavra seguinte.

Teste: “Qual é a capital do Brasil?”

Item	Resposta
Número de tokens	Verificar no tokenizador
Tokens gerados com IDs	Verificar no tokenizador
Observação	As palavras mais comuns costumam ser representadas por poucos tokens. O ponto de interrogação geralmente aparece como token separado. O espaço normalmente fica associado à palavra seguinte.

Parte 2 – O desafio do idioma e das palavras raras

Teste	O que observar	Resposta do aluno
Idioma	Compare “Let's go!” com “Vamos lá!”. Qual usou mais tokens? O que isso sugere?	Em muitos tokenizadores treinados principalmente em inglês, a frase em inglês tende a usar quantidade semelhante ou até menos tokens do que a frase em português. Isso sugere que palavras e expressões frequentes em inglês costumam ser representadas de forma mais eficiente.

Palavra rara	Teste “anticonstitucionalissimamente”. Virou um token só ou foi quebrada em pedaços?	A palavra normalmente é dividida em vários tokens menores, pois é longa e pouco frequente.
Internetês	Compare “pq vc n vem?” com “Por que você não vem?”. O que muda no número de tokens e na clareza?	As abreviações podem gerar uma tokenização diferente e nem sempre reduzem a quantidade de tokens. Além disso, a frase completa é mais clara e facilita a interpretação correta pelo modelo.

Parte 3 – Implicações práticas

A maioria das APIs de IA cobra por token. Se você precisa processar grande volume de texto em português, qual seria uma estratégia econômica? Justifique.

Uma estratégia econômica seria escrever de forma objetiva, evitando repetições desnecessárias e removendo informações redundantes. Também é possível resumir documentos antes de enviá-los ao modelo. Dessa forma, a quantidade de tokens processados diminui, reduzindo os custos.

Se uma palavra rara é quebrada em vários pedaços, por que o modelo pode ter mais dificuldade para lidar com ela?

Porque o modelo precisa interpretar vários fragmentos para reconstruir o significado da palavra. Como esses fragmentos podem ser pouco frequentes, a compreensão pode se tornar menos precisa.

Se um modelo tem limite máximo de tokens, como a tokenização afeta a quantidade de texto que você consegue enviar?

Quanto mais tokens um texto gerar, menor será a quantidade de conteúdo que poderá ser enviada dentro do limite de contexto do modelo. Palavras longas ou pouco comuns podem ocupar mais tokens e reduzir o espaço disponível para outras informações.

Perguntas de consolidação

Qual foi a tokenização mais inesperada que você encontrou? Houve alguma palavra que você achou que seria um token único, mas foi quebrada, ou o contrário?

A tokenização mais inesperada foi a da palavra “anticonstitucionalissimamente”. Eu imaginava que ela seria tratada como uma única unidade, mas foi dividida em vários tokens menores. Isso mostrou que os modelos trabalham com partes de palavras e não necessariamente com palavras completas.

Agora que você entende como o BPE funciona, você consegue pensar em uma “palavra-armadilha” que seria extremamente ineficiente para o tokenizador processar?

Sim. Uma palavra inventada e muito longa, como “supermegaultrahiperextraantidesenvolvimentisticamente”, provavelmente seria dividida em muitos tokens, tornando o processamento menos eficiente.

Como a compreensão da tokenização muda sua abordagem ao escrever prompts? Você passará a evitar gírias e abreviações? Como isso ajuda a obter resultados melhores?

Sim. Agora procuro escrever de forma mais clara, utilizando palavras completas e evitando abreviações excessivas. Isso facilita a compreensão do contexto pelo modelo, reduz ambiguidades e contribui para respostas mais precisas e de melhor qualidade.