

RELATÓRIO DE IA - SEMANA 14

Relatório: Feedback humano, privacidade e melhoria contínua em sistemas de IA

1. Compreensão do problema

- A IA precisa melhorar com base no uso real dos usuários.
- O feedback ajuda a identificar respostas confusas, incompletas ou incorretas.
- Se os erros não forem corrigidos, os usuários podem receber informações erradas e perder a confiança no sistema.

2. Feedback humano

- Feedback humano é a avaliação feita pelos usuários sobre as respostas da IA.
- Ele ajuda a identificar pontos que precisam ser melhorados.
- Formas de coleta:
 - Botões de aprovação e reprovação (👍/👎).
 - Notas e comentários curtos.

3. Privacidade antes do envio ao modelo

- Dados pessoais devem ser protegidos.
- Exemplos: nome completo, telefone, endereço e informações de saúde.
- Remover: apagar completamente o dado.
- Mascarar: ocultar parte da informação.
- Manter: conservar apenas quando for necessário e autorizado.

4. Uso do feedback para melhoria do modelo

- RLHF (Reinforcement Learning from Human Feedback) é uma técnica que utiliza avaliações humanas para melhorar a IA.
- O feedback ajuda a tornar as respostas mais úteis e precisas.
- O modelo não deve aprender automaticamente com qualquer feedback, pois algumas avaliações podem conter erros ou informações inadequadas.

5. Mecanismos de controle

- O feedback humano sozinho não garante segurança.
- Filtros bloqueiam conteúdos inadequados.
- Logs seguros registram informações de forma protegida.
- Auditorias verificam se as regras de segurança e privacidade estão sendo cumpridas.

Conclusão

- O feedback humano é importante para identificar problemas e melhorar a qualidade das respostas da IA.

- O retreinamento permite corrigir falhas e aperfeiçoar o sistema.
- A proteção de dados, os filtros, os logs seguros e as auditorias ajudam a garantir segurança e privacidade.
- Dessa forma, a IA pode evoluir continuamente de maneira confiável e responsável.